

Relatório Técnico

IADT – Fase 1 – Tech Challenge A

Turma / Disciplina	9IADT
Título do Projeto	Detecção de Síndrome dos Ovários Policísticos com Deep Learning (ResNet18)
Dataset utilizado	PCOS XAI Ultrasound Dataset – Kaggle (ibadeus)
Repositório Git	https://github.com/MacielMjose/diagnostico-medico-ml
Link do vídeo	https://www.youtube.com/watch?v=BPany5rsH-M
Nome(s) do(s) aluno(s)	Leonardo da Cunha Farias, Caio Lucas Santos Silva, Jose Luiz Marques Maciel, Samuel Maximo, Jefferson Santos

1. Resumo Executivo

Este projeto tem como objetivo a classificação automática de imagens de ultrassom ovariano para detecção da Síndrome dos Ovários Policísticos (SOP), condição endócrina que afeta entre 5% e 10% das mulheres em idade reprodutiva e é uma das principais causas de infertilidade feminina. A abordagem adotada combina Transfer Learning com a arquitetura ResNet18 pré-treinada no ImageNet, processamento de imagens de ultrassom e técnicas de explicação visual via Grad-CAM.

O dataset utilizado (“PCOS XAI Ultrasound Dataset”, Kaggle) contém 11.784 imagens distribuídas entre as classes infected (SOP presente) e noninfected (SOP ausente). Após um processo rigoroso de pré-processamento — que incluiu remoção de imagens duplicadas via hash MD5, balanceamento com WeightedRandomSampler e data augmentation seletivo — o modelo foi treinado por 8 épocas atingindo 97,03% de acurácia de validação e AUC de 0,9948, demonstrando excelente capacidade de generalização.

2. Contexto do Problema e Objetivo

2.1 Problema clínico

A SOP é um distúrbio endocrinometabólico caracterizado pela presença de múltiplos folículos ovarianos visíveis ao ultrassom (padrão “necklace sign”), irregularidade menstrual e hiperandrogenismo. O diagnóstico por imagem é eficaz, porém subjetivo e altamente dependente da experiência do radiologista. Modelos de inteligência artificial treinados para esta tarefa podem atuar como ferramentas de apoio à decisão clínica, aumentando a consistência e a velocidade do diagnóstico.

2.2 Objetivo do modelo

Classificar automaticamente imagens de ultrassom ovariano entre infected (presença de SOP) e noninfected (ausência de SOP), priorizando alta sensibilidade para a classe positiva (infected) e minimizando falsos negativos — situações em que pacientes com SOP seriam classificadas como saudáveis, gerando atraso no tratamento.

2.3 Hipótese inicial

Redes convolucionais pré-treinadas no ImageNet, mesmo não tendo sido treinadas em imagens médicas, são capazes de extrair características visuais relevantes — texturas, formas e padrões de bordas — que permitem diferenciar ovários policísticos de ovários saudáveis com alta acurácia, especialmente quando o fine-tuning é aplicado seletivamente na camada de saída.

3. Base de Dados

Nome do Dataset	PCOS XAI Ultrasound Dataset
Fonte / Link	https://www.kaggle.com/datasets/ibadeus/pcos-xai-ultrasound-dataset
Total de imagens	11.784 imagens (antes da deduplicação)
Após remoção de duplicatas	~3.996 imagens únicas (infected: 3.184 / noninfected: 812)
Variável-alvo	Classe binária: infected / noninfected
Tipo das variáveis	Imagens de ultrassom ovariano (JPG/PNG, redimensionadas para 224×224)
Possíveis limitações	Imagens duplicadas (identificadas e removidas); desbalanceamento severo após deduplicação (~4:1); ausência de metadados clínicos; variabilidade de equipamentos e técnicos.

3.1 Problema de duplicatas

O dataset bruto continha um volume significativo de imagens duplicadas — arquivos com conteúdo binário idêntico, detectados via hash MD5. Antes da deduplicação a distribuição era de 6.784 infected (57,6%) e 5.000 noninfected (42,4%), aparentando um desbalanceamento leve e aceitável. Após a remoção das duplicatas, a distribuição real revelou 3.184 infected (79,7%) e apenas 812 noninfected (20,3%), configurando um desbalanceamento severo de ~4:1 que demandou tratamento específico.

4. Análise Exploratória de Dados

A análise exploratória cobriu as seguintes dimensões:

- Distribuição das classes: verificada antes e após a deduplicação, revelando desbalanceamento latente oculto pelas duplicatas.
- Distribuição treino vs. validação: confirmada proporcional após o split 80/20 com seed fixo (42), sem vazão de dados.
- Qualidade visual: as imagens apresentaram boa qualidade, sem inconsistências críticas de resolução ou corrupção.
- Detecção de duplicatas: 7.788 imagens duplicadas identificadas via hash MD5 e removidas antes do split.

As visualizações geradas no notebook incluem: gráfico de distribuição de classes (total e por split), loss e acurácia por época, matriz de confusão, curva ROC/AUC e mapa Grad-CAM.

5. Pré-processamento

Etapa	Técnica	Justificativa
Remoção de Duplicatas	Hash MD5 por arquivo	Eliminação de data leakage por imagens idênticas entre treino e validação. O dataset bruto continha ~66% de duplicatas.
Padronização	Resize 224×224 px	Padrão de entrada da ResNet18; garante consistência dimensional entre todas as imagens.
Data Augmentation	RandomHorizontalFlip + RandomRotation($\pm 10^\circ$)	Aplicado exclusivamente no treino. Aumenta a variabilidade artificial das amostras e reduz overfitting.
Balanceamento	WeightedRandomSampler	Corrige o desbalanceamento 4:1 atribuindo peso inverso à frequência de cada classe no DataLoader. Não descarta dados.
Split treino/validação	80% treino / 20% validação (seed=42)	Split reprodutível via torch.Generator. Dois ImageFolder independentes garantem transforms corretos sem compartilhamento.
Normalização	ToTensor() $\rightarrow$ [0,1]	Converte PIL Image para tensor PyTorch e escala pixels para [0,1].

5.1 Detalhe: correção de transforms compartilhados

Uma armadilha comum do PyTorch foi identificada e corrigida: ao usar `random_split` em um único objeto `ImageFolder`, o atributo `.dataset` é compartilhado entre os dois Subsets. Alterar o transform de validação sobrescreveria o transform de treino também, desativando silenciosamente o data augmentation. A solução adotada foi criar dois objetos `ImageFolder` independentes — um com `train_transforms`, outro com `val_transforms` — e aplicar os índices de split como Subset em cada um.

6. Modelagem

6.1 Arquitetura e estratégia

Foi utilizada a arquitetura ResNet18 pré-treinada no ImageNet com abordagem de Transfer Learning. Todas as camadas convolucionais foram congeladas (`param.requires_grad = False`), e apenas a camada fully connected final foi substituída por uma `Linear(512, 2)` e re-treinada. Essa estratégia é adequada para datasets médicos de tamanho moderado, pois aproveita features visuais genéricas já aprendidas e reduz drasticamente o risco de overfitting.

Modelo base	ResNet18
Pesos iniciais	ImageNet (ResNet18_Weights.IMAGENET1K_V1)
Camadas treinadas	Apenas a camada fc (Linear 512 → 2)
Otimizador	Adam — lr = 0.001
Função de perda	CrossEntropyLoss
Épocas	8
Batch size	16
Device	CUDA (GPU T4 — Google Colab)
Classes de saída	infected (0) / noninfected (1)

6.2 Justificativa da escolha

Transfer Learning com ResNet18 foi escolhido por três razões principais: (1) o dataset, mesmo após deduplicação, possui ~4.000 imagens — insuficiente para treinar uma CNN do zero sem overfitting; (2) features aprendidas no ImageNet (bordas, texturas, formas) são transferíveis para imagens médicas de ultrassom; (3) treinar apenas a camada final reduz drasticamente o custo computacional e o risco de overfitting, sendo possível obter resultados competitivos em poucas épocas.

7. Resultados

7.1 Histórico de treinamento por época

Época	Train Loss	Train Acc	Val Loss	Val Acc
1	0.2599	89.37%	0.1374	95.29%
2	0.1873	92.37%	0.1627	94.44%
3	0.1659	92.98%	0.1757	93.04%
4	0.1531	93.95%	0.1068	96.18%
5	0.1602	93.17%	0.1107	95.88%
6	0.1615	93.40%	0.1335	95.38%
7 ★	0.1510	93.95%	0.0942	97.03%

★ Melhor época: menor val loss (0.0942) e maior acurácia de validação (97.03%). Não há sinais evidentes de overfitting — a acurácia de validação se mantém consistentemente elevada e a val loss converge.

7.2 Métricas finais de classificação

Métrica	Valor	Observação
Acurácia geral	~97%	Melhor época (7/8)
Recall (infected)	~98%	Alta sensibilidade — poucos falsos negativos
Precisão	~97%	Baixa taxa de falsos positivos
F1-Score	~97%	Equilíbrio precisão/recall
AUC	0.9948	Excelente poder discriminativo

7.3 Matriz de Confusão

A matriz de confusão demonstrou baixo número de falsos negativos (casos infected classificados como noninfected) — a métrica mais crítica do ponto de vista clínico, pois representa diagnósticos de SOP perdidos. Ambas as classes apresentaram alto número de acertos, confirmando que o modelo não possui viés significativo em favor da classe majoritária, resultado do WeightedRandomSampler aplicado durante o treinamento.




Figura — Matriz de Confusão

7.4 Curva ROC e AUC

A curva ROC apresentou AUC de 0.9948, indicando excelente capacidade discriminativa em todos os limiares de decisão. Em contextos clínicos, a curva ROC é especialmente útil pois permite ajustar o limiar de classificação para priorizar sensibilidade (recall de infected) em detrimento de especificidade, conforme a necessidade do especialista.




Figura — Curva ROC (AUC = 0.9948)

8. Explicabilidade (Grad-CAM)

Foi aplicada a técnica Grad-CAM (Gradient-weighted Class Activation Mapping) sobre a última camada convolucional da ResNet18 (layer4[-1]). O método gera mapas de ativação sobrepostos à imagem original, destacando as regiões que mais contribuíram para a decisão do modelo.




Figura — Grad-CAM: regiões de ativação do modelo

Os mapas gerados demonstraram que o modelo foca nas regiões periféricas do ovário, onde os folículos característicos da SOP se concentram — comportamento clinicamente coerente com o que radiologistas observam no diagnóstico visual. Esse resultado aumenta a confiabilidade do modelo e demonstra que ele aprendeu padrões relevantes, e não artefatos ou bordas de imagem.

Técnica XAI	Aplicação	Resultado
Grad-CAM	Camada layer4[-1] da ResNet18	Mapas de ativação focados em regiões periféricas do ovário (folículos — marcador clínico da SOP)

9. Uso Prático e Limitações

O modelo apresentou métricas elevadas e comportamento visual coerente com o conhecimento clínico, o que o torna promissor como ferramenta de apoio ao diagnóstico. Contudo, tratando-se de um trabalho acadêmico, é fundamental reconhecer as seguintes limitações antes de qualquer consideração de uso em ambiente produtivo:

- Dataset com abrangência geográfica limitada: a origem e diversidade étnica/demográfica das imagens não estão documentadas, o que pode limitar a generalização para populações distintas das do dataset de treino.
- Volume de dados após deduplicação: com ~4.000 imagens únicas, o dataset é modesto para um problema médico. Validação em datasets externos e independentes é necessária.
- Ausência de metadados clínicos: o modelo trabalha exclusivamente com a imagem, sem informações como idade, nível hormonal ou histórico da paciente, que seriam relevantes clinicamente.
- Necessidade de validação clínica: mesmo com AUC de 0.99, o modelo deve ser validado por profissionais médicos especialistas em imagem ovariana antes de qualquer consideração de uso assistivo.
- Palavra final do profissional: independentemente das métricas obtidas, o diagnóstico final deve sempre ser conduzido e confirmado por um médico qualificado. O modelo atua como suporte, nunca como substituto.

10. Reprodutibilidade

Repositório Git	https://github.com/MacieIMjose/diagnostico-medico-ml
Ambiente de execução	Google Colab (GPU T4)
Python	3.12
PyTorch	Versão atual no Colab — verificar <code>torch.__version__</code>
torchvision	Compatível com PyTorch instalado
scikit-learn	<code>classification_report</code> , <code>confusion_matrix</code> , <code>roc_curve</code> , <code>auc</code>
kagglehub	1.0.0 — download automático do dataset
Seed de reprodutibilidade	<code>torch.Generator().manual_seed(42)</code> no split treino/validação
Dataset	https://www.kaggle.com/datasets/ibadeus/pcos-xai-ultrasound-dataset

11. Referências

- [1] He, K. et al. (2016). Deep Residual Learning for Image Recognition. CVPR 2016.
- [2] Selvaraju, R. R. et al. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. ICCV 2017.
- [3] Dataset: PCOS XAI Ultrasound Dataset — <https://www.kaggle.com/datasets/ibadeus/pcos-xai-ultrasound-dataset>
- [4] PyTorch Documentation — <https://pytorch.org/docs/stable/>
- [5] torchvision.models.resnet18 — <https://pytorch.org/vision/stable/models/resnet.html>
- [6] scikit-learn: metrics — <https://scikit-learn.org/stable/modules/classes.html#module-sklearn.metrics>
- [7] Rotterdam ESHRE/ASRM-Sponsored PCOS Consensus Workshop Group (2004). Revised 2003 consensus on diagnostic criteria and long-term health risks related to polycystic ovary syndrome. Human Reproduction, 19(1), 41–47.

Documento gerado com base no notebook pocs_CNN_weight_balancer.ipynb — campos em branco devem ser preenchidos pelo aluno antes da entrega final.